

Spring AI: Modül 06

RAG Bölüm 2: İleri Düzey Arama, Yeniden Sıralama (Reranking) ve Değerlendirme Metrikleri

Üretim Standardında Kurumsal RAG Sistemleri

1. Basit (Naive) RAG Neden Üretimde Yetersiz Kalır?

- Vektör araması anlamsal olarak benzer ancak olgusal olarak yanlış parçalar getirebilir:
 - Yanlış yargı bölgesi (jurisdiction) veya geçerliliğini yitirmiş eski bir sözleşme yılı.
 - Madde numaraları ve tam kod aramalarında zayıf kalır.
- **Çözüm:** Hibrit Arama + Üst Veri Filtreleme (Metadata Filtering) + Bağlamsal Yeniden Sıralama (Reranking).

2. Spring AI'da Üst Veri Filtreleme

```
SearchRequest request = SearchRequest.builder()  
    .query("fesih ihbar süresi")  
    .topK(10)  
    .filterExpression("jurisdiction == 'TR' AND effectiveYear >= 2024")  
    .build();  
  
List<Document> candidates = vectorStore.similaritySearch(request);
```


- Filtre ifadeleri çok kiracılı (multi-tenant) sistemlerde veri sızıntılarını önler.

3. İki Kademeli Arama ve Sıralama (Two-Stage Retrieval)

```
[Sorgu] -> Aşama 1: Vektör Arama (Geniş 20 aday parça)  
        -> Aşama 2: Yeniden Sıralayıcı (En hassas 3 parça)  
        -> Aşama 3: LLM Yanıt Üretimi
```

- Milyonlarca dokümanı pahalı modellere sokmadan yüksek doğruluk (Precision@K) sağlar.

4. RAG Üçlüsü (RAG Triad) Değerlendirme Metrikleri



1. **Bağlam Uygunluğu:** İstenen bilgi doğru çekildi mi?

2. **Doğrulanabilirlik:** Yanıt yalnızca verilen bağlama mı dayanıyor?

5. Çıkarımlar ve İlkeler

1. Arama uzayını daraltmak için önce üst verilerle filtreleyin.
2. Aday parçaları LLM'e göndermeden önce yeniden puanlayın (rerank).
3. RAG Triad metrikleriyle halüsinasyonları üretimde otomatik denetleyin.