

Spring AI: Modül 08


Sohbet Danışmanları (Advisors), Bellek Sistemleri ve Konuşma Durumu

Durumsuz (Stateless) LLM Mimarilerinde Durum Yönetimi

1. Durumsuz (Stateless) LLM Problemi

- HTTP ve LLM API'leri doğası gereği durumsuzdur (stateless):
 - Her çağrı birbirinden bağımsız değerlendirilir.
 - Önceki konuşma geçmişi istemle (prompt) birlikte gönderilmezse model geçmişi hatırlamaz.
- **Spring AI Çözümü:** `ChatMemory` soyutlaması ve `MessageChatMemoryAdvisor`.

2. Spring AI ChatMemory Mimarisi



- Bellek sağlayıcıları: **InMemoryChatMemory**, Redis, JDBC, Cassandra.

3. `conversationId` ile Oturum İzolasyonu

```
String reply = chatClient.prompt()  
    .user(userMessage)  
    .advisors(a -> a.param(  
        AbstractChatMemoryAdvisor.CHAT_MEMORY_CONVERSATION_ID_KEY,  
        sessionId  
    ))  
    .call()  
    .content();
```

- Her kullanıcının konuşma geçmişi diğer kullanıcılardan kesin olarak yalıtılır.

4. Bağlam Patlamasını Önleme: Kayan Pencere (Sliding Window)

- Sınırlandırılmayan sohbet geçmişi zamanla devasa boyutlara ulaşır:
 - Token maliyetleri katlanır.
 - Modelin bağlam penceresi limiti aşılır.
- **Özel CallAroundAdvisor:** Mesaj sayısı veya token bütçesi aşıldığında en eski mesajları budar veya özetler.

5. Çıkarımlar ve İlkeler

1. Sohbet durumunu statik değişkenlerde tutmayın; `ChatMemory` kullanın.
2. Her oturumu benzersiz `conversationId` ile izole edin.
3. Token tüketimini sınırlamak ve hafızayı temiz tutmak için kayan pencere (sliding window) mekanizması kurun.